PORTFÓLIO DE ANÁLISE DE DADOS

Infraestrutura tecnológica das escolas

Ferramentas, métodos e decisões por trás do relatório em Power BI

Gustavo Oliveira · Power BI (Power Query e DAX) · SQL · Python · Databricks · Excel

Sobre este documento

Este documento explica, para quem avalia o projeto, quais ferramentas usei em cada etapa e por quê. O objetivo é mostrar o raciocínio por trás do relatório, do dado bruto até o visual final.

Pergunta do projeto	Como a infraestrutura tecnológica das escolas mudou ao longo dos anos, comparando as redes municipal, estadual e privada?
Fonte prevista	Microdados do Censo Escolar da Educação Básica (INEP), arquivo de escolas.
Recorte	Minas Gerais, uma linha por escola em atividade e por ano.
Sobre os números	**Os números exibidos no relatório são fictícios.** Gerei uma amostra sintética com o mesmo formato, os mesmos nomes de coluna e a mesma codificação dos microdados do INEP para demonstrar a lógica e as ferramentas. O pipeline já está pronto para processar os dados reais com um único comando.

1. Visão geral da arquitetura

O projeto segue a **arquitetura medalhão**, um padrão de Data Lake em que o dado passa por camadas de qualidade crescente. O dado bruto nunca é alterado, e todas as regras de negócio ficam em SQL versionado. Por isso o processo é um **ELT**: primeiro carrego (Load), depois transformo (Transform) dentro do banco.



Python + DuckDB no computador local | Spark + Delta Lake no Databricks | o mesmo SQL nos dois

Camada	O que acontece	Ferramenta
Raw	Os zips originais do INEP são baixados e guardados sem alteração.	Python
Bronze	O CSV de cada ano é carregado como veio, com o nome do arquivo de origem e a ordem de carga.	Python + DuckDB (Parquet) ou Spark (Delta)
Silver	Tipagem segura, filtro de UF e de escolas em atividade, tratamento de nulos e remoção de duplicidades.	SQL
Gold	Modelo estrela (dimensões e fato), cálculo do índice e data marts agregados.	SQL

Camada	O que acontece	Ferramenta
Consumo	Relatório interativo e planilha analítica.	Power BI e Excel

2. Ferramentas e o papel de cada uma

Ferramenta	Para que usei	Onde está no projeto
Python	Orquestrar o pipeline: download, extração dos zips, execução do SQL, exportação e atualização automática do Excel e do Power BI. Também gerei a amostra sintética.	pipeline/
DuckDB	Banco analítico local que funciona como Data Warehouse. Lê CSV e Parquet direto e roda SQL analítico com rapidez, sem servidor.	dados/dw_infra_tec.duckdb
SQL	Todas as regras de negócio: limpeza, modelo estrela, índice, data marts e consultas analíticas.	sql/
Databricks	O mesmo pipeline em nuvem, com Spark, tabelas Delta Lake, Unity Catalog e Volumes. Usa os mesmos arquivos SQL do ambiente local.	databricks/
Power Query	Conexão aos arquivos da camada gold, tipagem, renomeação, limpeza de texto e colunas derivadas, com parâmetro de pasta.	Modelo do Power BI
Power BI (modelo)	Modelo estrela com relacionamentos 1:N, colunas de ordenação e medidas organizadas em pastas.	InfraTecEscolas.SemanticModel
DAX	31 medidas: indicadores, comparação com o ano anterior, evolução no período, diferença entre público e privado, ranking e texto automático.	Tabela Medidas
Power BI (relatório)	5 páginas interativas com tema de cores próprio.	InfraTecEscolas.Report
Excel	Planilha para quem não usa Power BI: tabela dinâmica, busca com dois critérios, validação de dados, formatação condicional e gráfico.	excel/
Git e GitHub	Versionamento de todo o projeto. O Power BI está no formato .pbip (texto), o que permite ver cada mudança em medidas e visuais.	Repositório
Kanban	Organização do trabalho em 3 sprints, com histórias, critérios de aceite e definição de pronto.	docs/backlog_kanban.md

3. SQL: regras de negócio versionadas

Escrevi o SQL em padrão ANSI para que os mesmos arquivos rodem no DuckDB e no Databricks. Os recursos principais:

- **CTEs** (*WITH*) para dividir cada transformação em etapas legíveis.
- **TRY_CAST** e **COALESCE** para tipar com segurança: valor inválido vira nulo e não quebra a carga.
- **QUALIFY + ROW_NUMBER** para garantir uma única linha por escola e ano.
- **Funções de janela**: LAG (variação ano a ano), FIRST_VALUE (variação desde o início), RANK e NTILE (posição e quartil).
- **Agregação condicional** (*CASE* dentro de *AVG*) para pivotar redes em colunas.
- **PERCENTILE_CONT** para a mediana de alunos por computador.

Exemplo: deduplicação na camada silver

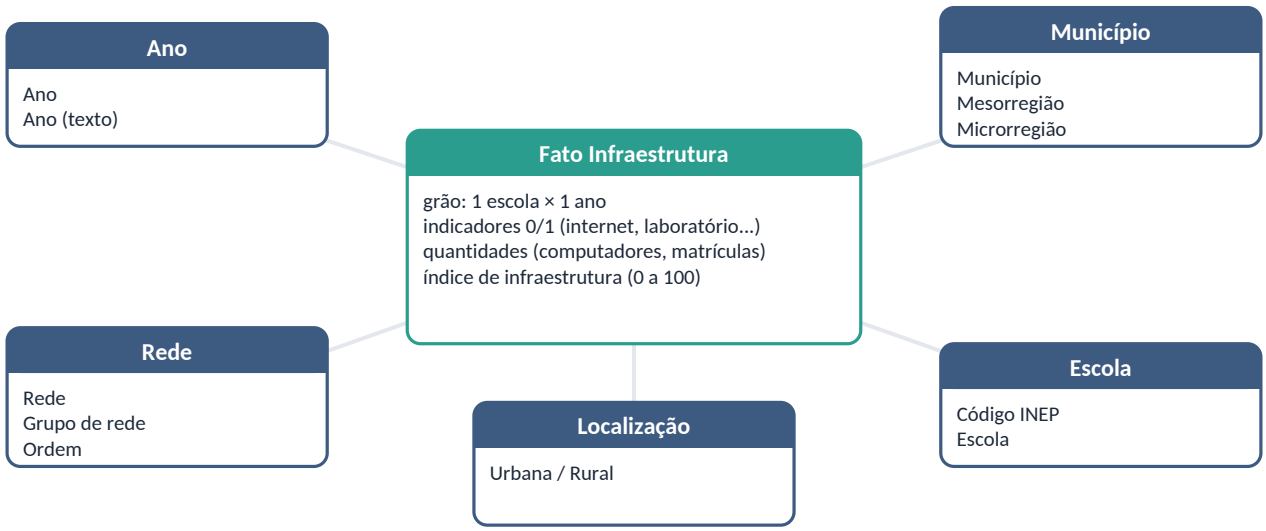
```
SELECT *
FROM tipado
WHERE sg_uf = 'MG'
  AND tp_situacao_funcionamento = 1          -- somente escolas em atividade
QUALIFY ROW_NUMBER() OVER (
    PARTITION BY ano, co_entidade ORDER BY _ordem_carga DESC) = 1;
```

Exemplo: variação ano a ano por rede (data mart)

```
SELECT
    a.*,
    a.indice_infra_tec
      - LAG(a.indice_infra_tec) OVER (PARTITION BY a.rede ORDER BY a.ano) AS delta_indice_ano_anterior,
    RANK() OVER (PARTITION BY a.ano ORDER BY a.indice_infra_tec DESC)       AS posicao_no_ano
FROM agregado a;
```

4. Modelagem: Data Warehouse em modelo estrela

A tabela fato tem o grão **uma escola por ano**. As dimensões descrevem o ano, a rede (dependência administrativa), a localização, o município e a escola. Esse desenho deixa as medidas simples e os filtros previsíveis, e é o formato recomendado para o Power BI.



Índice de Infraestrutura Tecnológica (0 a 100)

Para responder à pergunta com um número comparável entre anos e redes, criei um índice que soma pesos dos recursos que a escola declara ter. Cada componente também aparece separado no relatório.

Componente	Peso
Internet	20
Banda larga	15
Internet para uso dos alunos	15
Internet no ensino e aprendizagem	10
Laboratório de informática	15
Computador, notebook ou tablet para alunos	15
Rede local (cabo ou sem fio)	10

5. Power Query

- **Parâmetro PastaDados**: o caminho dos arquivos fica num só lugar, e o pipeline o preenche sozinho.
- **Tratamento de erro** (*try … otherwise*): se a pasta não existir, o modelo usa uma cópia compactada da amostra guardada no próprio projeto, e o relatório abre em qualquer computador.
- **Tipagem explícita com cultura en-US**, para que decimais com ponto não virem texto em computadores configurados em português.
- **Renomeação** de colunas técnicas para nomes amigáveis e **Text.Proper** nos nomes das escolas.
- **Coluna derivada** "Porte da escola", por faixa de matrículas.

6. DAX

As medidas ficam numa tabela própria, separadas em pastas: Base, Indicadores (%), Evolução no tempo, Público x privado e Textos e rankings. Funções usadas: CALCULATE, DIVIDE, REMOVEFILTERS, ALLSELECTED, RANKX, ISINSCOPE, SUMMARIZE, FILTER, CONCATENATEX e variáveis (VAR).

Exemplo: comparação com o ano anterior

```
Índice no ano anterior =
VAR _ano = MAX ( 'Ano'[Ano] )
RETURN
    CALCULATE (
        [Índice de infraestrutura tecnológica],
        REMOVEFILTERS ( 'Ano' ),
        'Ano'[Ano] = _ano - 1
    )
```

Exemplo: texto automático que resume a evolução de cada rede

```
VAR _redes =
    FILTER ( SUMMARIZE ( 'Rede', 'Rede'[Rede], 'Rede'[Ordem] ),
             NOT ISBLANK ( [Índice de infraestrutura tecnológica] ) )
VAR _texto =
    CONCATENATEX ( _redes,
        'Rede'[Rede] & ": " & FORMAT ( _a, "0.0" ) & " → " & FORMAT ( _b, "0.0" ),
        "   •   ", 'Rede'[Ordem], ASC )
```

Como os cartões mostram um único ano, criei medidas "no ano de referência", que usam o último ano do filtro. Assim os números do topo continuam corretos quando a pessoa seleciona vários anos.

7. O relatório

Página	O que responde
Visão geral	Indicadores do ano de referência, evolução do índice por rede e um resumo automático em texto.
Indicadores ao longo do tempo	Quatro componentes separados: internet para alunos, banda larga, laboratório e computador para alunos.
Público x privado	Se a diferença entre a rede privada e a pública diminuiu, com matriz rede × ano.
Municípios	Ranking dos municípios pelo índice, com tabela e gráfico de barras.
Sobre o projeto	Pergunta, fonte, arquitetura, método do índice e limitações.

Cores (tema "Lousa Digital")

Escolhi cores ligadas à escola e mantive cada rede sempre com a mesma cor em todos os gráficos, para a leitura ficar imediata:

Municipal: verde-lousa Estadual: azul Federal: amarelo-giz Privada: coral

O cabeçalho em azul-marinho e o fundo claro dão contraste sem cansar a leitura. Usei uma única cor de alerta (coral) para diferenças e avisos.

8. Excel

- **Tabela estruturada** (tbRedeAno) gerada pela camada gold, referenciada pelo nome nas fórmulas.
- **Tabela dinâmica** com o índice médio por rede e ano, atualizada ao abrir o arquivo.
- **Seletores com validação de dados** (listas suspensas de ano e rede).
- **ÍNDICE + CORRESP com dois critérios** (fórmula de matriz), SOMASES, MÉDIASES, CONT.SES e SEERRO.
- **Formatação condicional** (escala de cores e cor para variação positiva ou negativa) e gráfico de linhas.

9. Organização do trabalho

Organizei o projeto em Kanban com 3 sprints de uma semana: dados e ingestão, modelagem e regras, e entrega. Cada cartão tem uma história, um critério de aceite e segue uma definição de pronto (código versionado, números conferidos e documentação atualizada). Os cartões podem ser importados no GitHub Projects.

Conferência dos números

Para garantir que o relatório mostra o que deveria, recalculei de forma independente os principais indicadores (índice, % com internet, número de escolas, alunos por computador e diferença entre público e privado) e comparei com os data marts em SQL. Também verifiquei que não há escola duplicada no mesmo ano e que o índice fica sempre entre 0 e 100.

10. Limitações e próximos passos

- Os números deste relatório são fictícios. O próximo passo é processar os microdados reais do INEP.
- No Censo, os dados são declarados pelas escolas. Ter o recurso não garante uso pedagógico nem qualidade da conexão.
- Os pesos do índice são uma escolha documentada e podem ser ajustados.
- Próximos passos: cruzar com o IDEB, publicar no Power BI Service e agendar a atualização anual no Databricks.